REPERTÓRIO · BIBLIOGRAFIA OFICIAL DA ENTREVISTA ESPM

Cathy O'Neil — Algoritmos de destruição em massa

Como a matemática vendida como neutra passou a decidir quem estuda, trabalha, recebe crédito e vai preso

Como usar este dossiê

O verbete do caderno de repertórios é a ficha; isto aqui é o livro inteiro. Leia uma vez de ponta a ponta — ele foi escrito como uma linha de raciocínio, da biografia da autora até as críticas ao livro. Depois use as seções 8 (perguntas), 9 (introdução com fonte) e 10 (glossário) como consulta.

Algoritmos de destruição em massa (2016; no Brasil, Editora Rua do Sabão, 2020) está na bibliografia da sua entrevista e cobre três temas que a ESPM já cobrou: algoritmos e redes (2022-2), inteligência artificial nos negócios (2024-2) e IA e criação (2025-2 e 2026-1).

1. Quem é Cathy O'Neil — e por que a biografia dela é o argumento

Cathy O'Neil é matemática, doutora por Harvard, e foi professora universitária. Em 2007 trocou a universidade por um fundo de investimentos em Wall Street — meses antes da crise financeira. Foi dali, de dentro, que ela viu o que depois virou livro.

A crise de 2008 nasceu de modelos matemáticos. Títulos lastreados em hipotecas de pessoas que não conseguiriam pagar recebiam nota máxima de segurança, porque os modelos partiam de duas premissas: que o preço dos imóveis nunca cairia em todo o país ao mesmo tempo, e que os calotes seriam independentes uns dos outros. **A conta estava certa; a premissa estava errada.** E como era matemática, ninguém questionava. Quando as premissas falharam, o erro já tinha escala mundial — e quem pagou foram famílias que perderam casa e emprego, não quem desenhou os modelos.

O'Neil saiu do mercado financeiro, trabalhou com modelagem de risco, participou do movimento Occupy Wall Street e depois foi ser cientista de dados numa empresa de publicidade digital. Lá reconheceu o mesmo mecanismo migrando das finanças para a vida comum: modelos opacos, com aura de objetividade, decidindo sobre milhões de pessoas. O livro é a tentativa de nomear esse padrão.

> **A cadeia que abre o livro:** modelos com aura de neutralidade → erro de premissa aplicado em escala → dano concentrado nos mais vulneráveis → ninguém responsabilizado → a mesma lógica sai de Wall Street e entra na escola, no tribunal, no RH e no banco.

2. A tese e a anatomia de uma "arma"

Um modelo é uma opinião escrita em linguagem matemática

O'Neil começa com um exemplo doméstico. Quando ela decide o jantar dos filhos, usa um "modelo" na cabeça: o que tem na geladeira, quanto tempo há, o que cada um come. E define o que é sucesso: os filhos comerem legumes. Se o filho mais novo desenhasse o modelo, sucesso seria comer chocolate. **O modelo é**

o mesmo; o objetivo é uma escolha de valor. Todo modelo decide o que conta e o que ignora — e essa decisão é humana, mesmo quando depois vira código.

Os três traços de uma arma de destruição matemática

Nem todo algoritmo é perigoso. Ele vira arma quando reúne os três:

1. **Opacidade** — quem é avaliado não sabe como a decisão foi tomada, e muitas vezes nem sabe

que foi avaliado.

1. **Escala** — o modelo decide sobre milhões; um erro vira um padrão.
2. **Dano** — a decisão tira algo importante: emprego, crédito, vaga, liberdade.

Dois mecanismos que transformam modelo em injustiça

Os substitutos (proxies). O que se quer medir quase nunca é mensurável diretamente: "esta pessoa vai pagar o empréstimo?", "este professor ensina bem?". Então o modelo usa algo parecido e fácil de medir — o CEP, os amigos, o jeito de preencher um formulário. O problema é que esses substitutos acompanham pobreza e raça. **O modelo discrimina sem precisar dizer a palavra.**

O ciclo que se retroalimenta. O modelo age sobre o mundo, e o mundo que ele produziu vira o dado que o confirma. Um sistema manda mais policiais a um bairro; mais policiais registram mais ocorrências ali; mais ocorrências "provam" que o sistema acertou.

A frase que resume os dois: **modelos de big data codificam o passado — eles não inventam o futuro.** Se o passado foi injusto, o modelo automatiza a injustiça, agora com aparência de ciência.

O contraexemplo: quando um modelo é saudável

O'Neil usa o beisebol americano como modelo bom: as estatísticas medem **diretamente** o que importa (pontos, rebatidas), são **públicas**, e o modelo é **corrigido o tempo todo** pelo resultado real. Transparência, medida direta e correção constante — exatamente o que falta nas armas.

---

3. A viagem pelo livro: um caso por área

Cada caso abaixo prova um elo diferente. Saber qual elo é o que permite usar o caso com precisão.

Educação: o ranking que reorganizou as universidades

Em 1983, a revista *U.S. News & World Report* passou a ranquear as universidades americanas. Como "qualidade de ensino" não se mede direto, o ranking usou substitutos: notas de ingresso dos alunos, taxa de rejeição, doações de ex-alunos, reputação entre dirigentes. **O custo da mensalidade não entrava na conta.** As universidades passaram a otimizar os substitutos: gastar em instalações vistosas, recusar candidatos para parecer seletivas — algumas chegaram a falsificar dados. Resultado: uma corrida de preços que endividou gerações de estudantes. Uma faculdade que se recusou a participar, o Reed College, caiu no ranking. **Elo que prova:** substituto mal escolhido + escala = o sistema inteiro se deforma para agradar à métrica.

Professores: a nota que ninguém sabia explicar

Em Washington, um sistema de avaliação de professores por "valor agregado" demitiu em 2011 a professora Sarah Wysocki, elogiada pela direção e pelas famílias. A nota dela caiu porque os alunos chegaram com notas do ano anterior suspeitas de terem sido infladas por fraude — então, "pioraram" na turma dela. Além disso, uma turma de 25 alunos é pequena demais para separar mérito de acaso. Ninguém conseguia explicar a nota; ninguém podia contestá-la. **Elo:** amostra pequena + opacidade + consequência grave = injustiça com carimbo técnico.

Faculdades com fins lucrativos: o anúncio que caça vulneráveis

Documentos internos de uma rede de faculdades particulares, a Corinthian Colleges, descreviam o aluno-alvo como isolado, impaciente e com baixa autoestima. A publicidade digital permitia achar exatamente essas pessoas na hora de maior fragilidade. Elas contraíam empréstimos estudantis públicos para cursos caros e de baixa conclusão. A rede fechou em 2015, depois de acusações de fraude. **Elo:** dado de vulnerabilidade + anúncio preciso = lucro com o endividamento de quem menos pode.

Justiça: o questionário que pune o bairro

Tribunais americanos usam modelos de risco de reincidência para ajudar a decidir penas e liberdade condicional. Um dos questionários mais usados pergunta, por exemplo, sobre o primeiro contato com a polícia e sobre amigos e parentes com passagem. Num país em que jovens negros e pobres são abordados muito mais cedo, essas perguntas funcionam como substitutos de raça e classe. Pena mais longa reduz as chances de emprego na saída, o que aumenta a reincidência — que então "confirma" o modelo. No **policiamento preditivo** (o PredPol é o exemplo do livro), incluir pequenas infrações nos dados leva mais patrulhas aos bairros pobres, onde se registram mais infrações, o que leva mais patrulhas. **Elo:** o ciclo que se retroalimenta, no caso mais grave — a liberdade.

Trabalho: a entrevista que acontece antes da entrevista

Kyle Behm, um universitário que tinha se tratado de transtorno bipolar, foi recusado por várias redes de varejo que usavam o mesmo teste de personalidade on-line — com perguntas que se aproximavam de triagem de saúde mental. Nenhum humano chegou a entrevistá-lo. E há os softwares de escala: otimizam, minuto a minuto, quantos funcionários uma loja precisa. A barista Jannette Navarro, de uma grande rede de cafés, retratada pelo *New York Times* em 2014, recebia a escala com poucos dias de antecedência e fechava a loja à noite para abri-la de manhã — sem conseguir planejar creche nem estudo. **Elo:** eficiência para a empresa = instabilidade planejada para o trabalhador.

Crédito: o bom exemplo e o mau

O score de crédito tradicional americano (FICO) tem defeitos, mas usa **o seu próprio histórico** de pagamentos, é regulado e pode ser contestado. Os "e-scores" são outra coisa: montados a partir de CEP, navegação e compras, não são regulados, e a pessoa nem sabe que existem — mas eles decidem que ofertas ela vê e em que fila do atendimento cai. **Elo:** a diferença entre um modelo que avalia você e um que avalia "gente parecida com você".

Seguros: quando a ficha limpa vale menos que o crédito bom

Uma investigação da revista *Consumer Reports* (2015) mostrou que, na Flórida, motoristas com ficha de trânsito limpa e crédito ruim pagavam mais pelo seguro do que motoristas com crédito excelente e

condenação por dirigir embriagado. O preço refletia menos o risco de acidente e mais a chance de o cliente pesquisar e trocar de seguradora. **Elo:** o modelo otimiza lucro, não justiça — e a métrica escolhida denuncia isso.

Democracia: o botão "eu votei"

Em 2010, o Facebook mostrou a 61 milhões de usuários quais amigos já tinham votado. O estudo, publicado na revista *Nature* em 2012, estimou cerca de 340 mil votos a mais. Se uma plataforma consegue mudar o comparecimento com um botão, consegue mudar quem vota. E a propaganda política microssegmentada permite que cada eleitor veja um candidato diferente — sem que ninguém veja o conjunto. O caso Cambridge Analytica (2018), posterior ao livro, confirmou o alerta. **Elo:** poder de moldar comportamento em escala, sem prestação de contas.

---

4. O fio que liga todos os casos

Depois de oito áreas, o padrão fica nítido, e é ele que você deve saber explicar:

> **(1)** um objetivo difícil de medir → **(2)** um substituto fácil → **(3)** decisão automática em escala → **(4)** quem é prejudicado não sabe e não pode contestar → **(5)** o resultado vira o dado que confirma o modelo.

E há uma assimetria que O'Neil faz questão de mostrar: **os privilegiados são avaliados por pessoas; as massas, por máquinas.** Quem estuda numa escola cara é entrevistado por gente; quem disputa uma vaga de balcão é filtrado por um teste automático. A automação não atinge todos por igual — ela recai sobre quem tem menos poder para reclamar.

---

5. O que ela propõe

1. **Auditoria de algoritmos.** Depois do livro, O'Neil fundou uma empresa dedicada a auditar algoritmos — examinar dados, objetivos e efeitos antes e depois de o sistema entrar em uso.
1. **Transparência e direito de contestação.** Quem é avaliado deve poder saber o que conta e recorrer — o score de crédito regulado é o parâmetro mínimo.
1. **Um juramento para quem modela.** Ela retoma o "juramento hipocrático dos modeladores", proposto por dois especialistas em finanças depois da crise: lembrar que o modelo não é o mundo, e que o erro dele cai sobre pessoas.
1. **Pôr a justiça dentro do objetivo.** Aceitar perder um pouco de eficiência para não discriminar — e medir isso.
1. **Usar os mesmos modelos para ajudar.** Um modelo que identifica famílias em risco pode mandar assistência em vez de polícia. O problema não é a matemática, é para que ela é usada.

6. E no Brasil

- **Reconhecimento facial na segurança pública:** levantamento da **Rede de Observatórios da

Segurança **(2019) apontou que** 90,5% das pessoas presas com base em reconhecimento facial eram negras**. Há casos documentados de prisão por erro de identificação.

- **LGPD (Lei 13.709/2018), artigo 20:** garante o direito de pedir revisão de decisões tomadas

unicamente por tratamento automatizado de dados — é a versão brasileira do "direito de contestar".

- **Score de crédito e Cadastro Positivo:** desde 2019 a inclusão no cadastro é automática; o

debate sobre que dados entram no score é exatamente o debate de O'Neil.

- **Marco regulatório da IA (PL 2338/2023):** aprovado no Senado em dezembro de 2024 e enviado à

Câmara. Confira em que etapa está antes de citar.

- **Aplicativos de trabalho:** o algoritmo define corrida, preço e bloqueio do motorista — o caso

brasileiro mais próximo das "escalas otimizadas" do livro (liga com o verbete da uberização).

7. As críticas — cinco leituras rivais

a) "Comparado a quê?" — economistas e cientistas de dados. O juiz humano também é enviesado, cansado, inconsistente. Um estudo de Jon Kleinberg e colegas (2018) com decisões de fiança em Nova York estimou que um algoritmo poderia reduzir em cerca de 40% as prisões preventivas sem aumentar a criminalidade. Para esse campo, a pergunta certa não é "o algoritmo é perfeito?", e sim "ele é melhor que o humano que ele substitui?".

b) Os estatísticos: "justiça" tem definições que não cabem juntas. Em 2016, o site ProPublica mostrou que um sistema de risco (COMPAS) errava mais contra réus negros, classificando-os como perigosos sem que reincidissem. A empresa respondeu que as notas eram igualmente precisas para os dois grupos. As duas coisas eram verdade — e pesquisadores provaram que, quando os grupos têm taxas de base diferentes, **é matematicamente impossível** satisfazer todos os critérios de justiça ao mesmo tempo. Consequência: escolher qual justiça priorizar é uma **decisão política**, não técnica.

c) Liberal de mercado: cuidado com o remédio. Regulação detalhada pode proteger quem já é grande (só gigantes pagam auditorias caras) e exigir abrir segredo industrial, facilitando que o sistema seja burlado. Preferem responsabilizar pelos **resultados** (quem discrimina paga) e estimular concorrência — e lembram que o próprio score regulado nasceu de pressão de consumidores e da lei de crédito, não da proibição de modelos.

d) Esquerda estrutural: o problema não é a matemática. Autoras como Ruha Benjamin e Safiya Noble argumentam que o racismo e a desigualdade são estruturais e que "auditar" pode legitimar sistemas que deveriam ser proibidos — como o reconhecimento facial no policiamento. Para elas, consertar o algoritmo sem mudar a estrutura é pintar a cerca.

e) O limite do próprio livro. É de 2016, anterior à IA generativa, centrado nos EUA e baseado em casos. Mas o critério — opacidade, escala e dano — envelheceu bem, e serve para julgar sistemas que ela nem

conheceu.

> **Como se posicionar com nuance:** *"O'Neil acerta ao mostrar que a aparência de neutralidade esconde escolhas de valor; mas, como apontam os estatísticos, decidir o que é uma decisão justa não é tarefa técnica. Por isso a saída passa por transparência e direito de contestação — e não por confiar cegamente nem proibir por princípio."*

---

8. Banco de perguntas — 16, com resposta

1. Qual é a tese do livro? Que modelos matemáticos com aparência de neutralidade passaram a decidir sobre milhões de pessoas e, quando são opacos, operam em escala e causam dano, automatizam e ampliam desigualdades.

2. O que é uma "arma de destruição matemática"? Um modelo que reúne opacidade, escala e dano. Faltando um dos três, pode ser só um modelo ruim — não uma arma.

3. Por que ela diz que um modelo é uma opinião? Porque todo modelo escolhe o que conta como sucesso. O exemplo do jantar dos filhos: legumes ou chocolate — o método é igual, o valor muda.

4. O que é um substituto (proxy) e por que ele é perigoso? É a variável fácil usada no lugar da difícil. É perigoso porque CEP, amigos ou histórico policial acompanham raça e pobreza: discrimina sem dizer a palavra.

5. O que é o ciclo que se retroalimenta? O modelo age no mundo e o mundo alterado vira o dado que o confirma — como no policiamento preditivo.

6. Dê um exemplo de modelo saudável. As estatísticas do beisebol: medida direta, dados públicos e correção constante pelo resultado real.

7. Como a biografia dela explica o livro? Ela viu por dentro, em 2008, modelos matemáticos com premissas erradas causarem a crise sem que ninguém fosse responsabilizado.

8. Qual caso mostra a injustiça com um indivíduo? A professora Sarah Wysocki, demitida por uma nota que ninguém sabia explicar nem contestar.

9. Qual caso mostra o ciclo mais grave? Os modelos de reincidência: a pena mais longa piora a vida na saída e aumenta a reincidência, que confirma o modelo.

10. Quem sofre mais com essas armas? Quem tem menos poder: os privilegiados são avaliados por pessoas; as massas, por máquinas.

11. O que ela propõe? Auditoria, transparência, direito de contestar, justiça dentro do objetivo do modelo e uso dos mesmos modelos para ajudar em vez de punir.

12. Qual é a crítica mais forte? A dos estatísticos: as definições de justiça são matematicamente incompatíveis, então "consertar o viés" exige uma escolha política.

13. E a crítica "comparado a quê"? Humanos também são enviesados; em alguns casos, um algoritmo transparente decide melhor que um juiz cansado.

14. Como isso aparece no Brasil? No reconhecimento facial (90,5% dos presos eram negros, segundo a Rede de Observatórios da Segurança, 2019) e no direito de revisão da LGPD, artigo 20.

15. Como liga com o curso de comunicação? A publicidade microssegmentada é um dos casos do livro: o mesmo dado que acha o consumidor certo acha o vulnerável certo. Ética na segmentação é questão do seu futuro trabalho.

16. Uma frase para fechar. Algoritmos não são neutros: são decisões humanas repetidas em escala — e por isso precisam de alguém que responda por elas.

---

9. Como usar na redação

Introdução em 6 linhas, com fonte (tema da ESPM 2022-2, algoritmos e relações humanas) — 67 palavras:

> Em *Algoritmos de destruição em massa* (2016), a matemática Cathy O'Neil mostra que modelos automatizados se tornam nocivos quando reúnem opacidade, escala e dano — e produzem os dados que os confirmam. A lógica alcança as redes sociais, que decidem o que cada usuário vê. Nesse sentido, ao otimizar o engajamento sem prestar contas de seus critérios, as plataformas convertem preferências em bolhas e fragilizam o debate comum.

Lembre da sua regra: se O'Neil abrir a introdução, **os desenvolvimentos precisam de outros repertórios**. Se ela entrar no desenvolvimento, use **um caso**, com fonte, como prova — Sarah Wysocki para educação, os e-scores para consumo, o reconhecimento facial para desigualdade.

---

10. Glossário

Termo	Uma linha
Modelo	simplificação do mundo que decide o que conta e o que ignora
Arma de destruição matemática	modelo opaco, em escala e que causa dano
Substituto (proxy)	variável fácil usada no lugar da difícil — e que carrega preconceito
Ciclo de retroalimentação	o modelo produz o dado que o confirma
Valor agregado	nota de professor pela evolução dos alunos — ruidosa em turmas pequenas
E-score	pontuação oculta montada com CEP, navegação e compras
Microssegmentação	anúncio feito para um perfil estreito de pessoas
Auditoria algorítmica	exame independente de dados, objetivo e efeitos de um sistema

---

11. Erros comuns ao citar

- **Dizer que O'Neil é contra algoritmos.** Ela é contra modelos opacos, em escala e sem contestação.
- **Citar só "algoritmos são enviesados".** Todo mundo diz isso; explique o **mecanismo** (substituto

ou ciclo) e dê **um caso com fonte**.

- **Chamar o livro de "sobre redes sociais".** Redes são um capítulo; o livro é sobre decisões automatizadas em educação, justiça, trabalho, crédito e política.
- **Esquecer o ano (2016).** Não atribua a ela opiniões sobre ChatGPT ou IA generativa.

Minhas dúvidas deste dossiê

Toda vez que uma palavra, um nome ou um trecho de **Cathy O'Neil — Algoritmos de destruição em massa** te fizer parar, escreva aqui **na hora** — não interrompa a leitura para pesquisar. Quando terminar o dossiê, volte e preencha as outras colunas. Escrever o significado **com as suas palavras** é o que fixa; copiar a definição não fixa.

	Palavra, nome ou trecho	O que é, nas minhas palavras	Onde eu uso (prova · redação · entrevista)
1			
2			
3			
4			
5			
6			
7			
8			
9			
10			
11			
12			
13			
14			
15			
16			

As 3 dúvidas que eu não consegui resolver sozinha

Estas vão para o Áthila ou para a professora. Pergunta escrita é pergunta respondida; pergunta na cabeça volta no dia da prova.

	A dúvida, escrita como pergunta	A resposta que eu recebi
1		
2		
3		